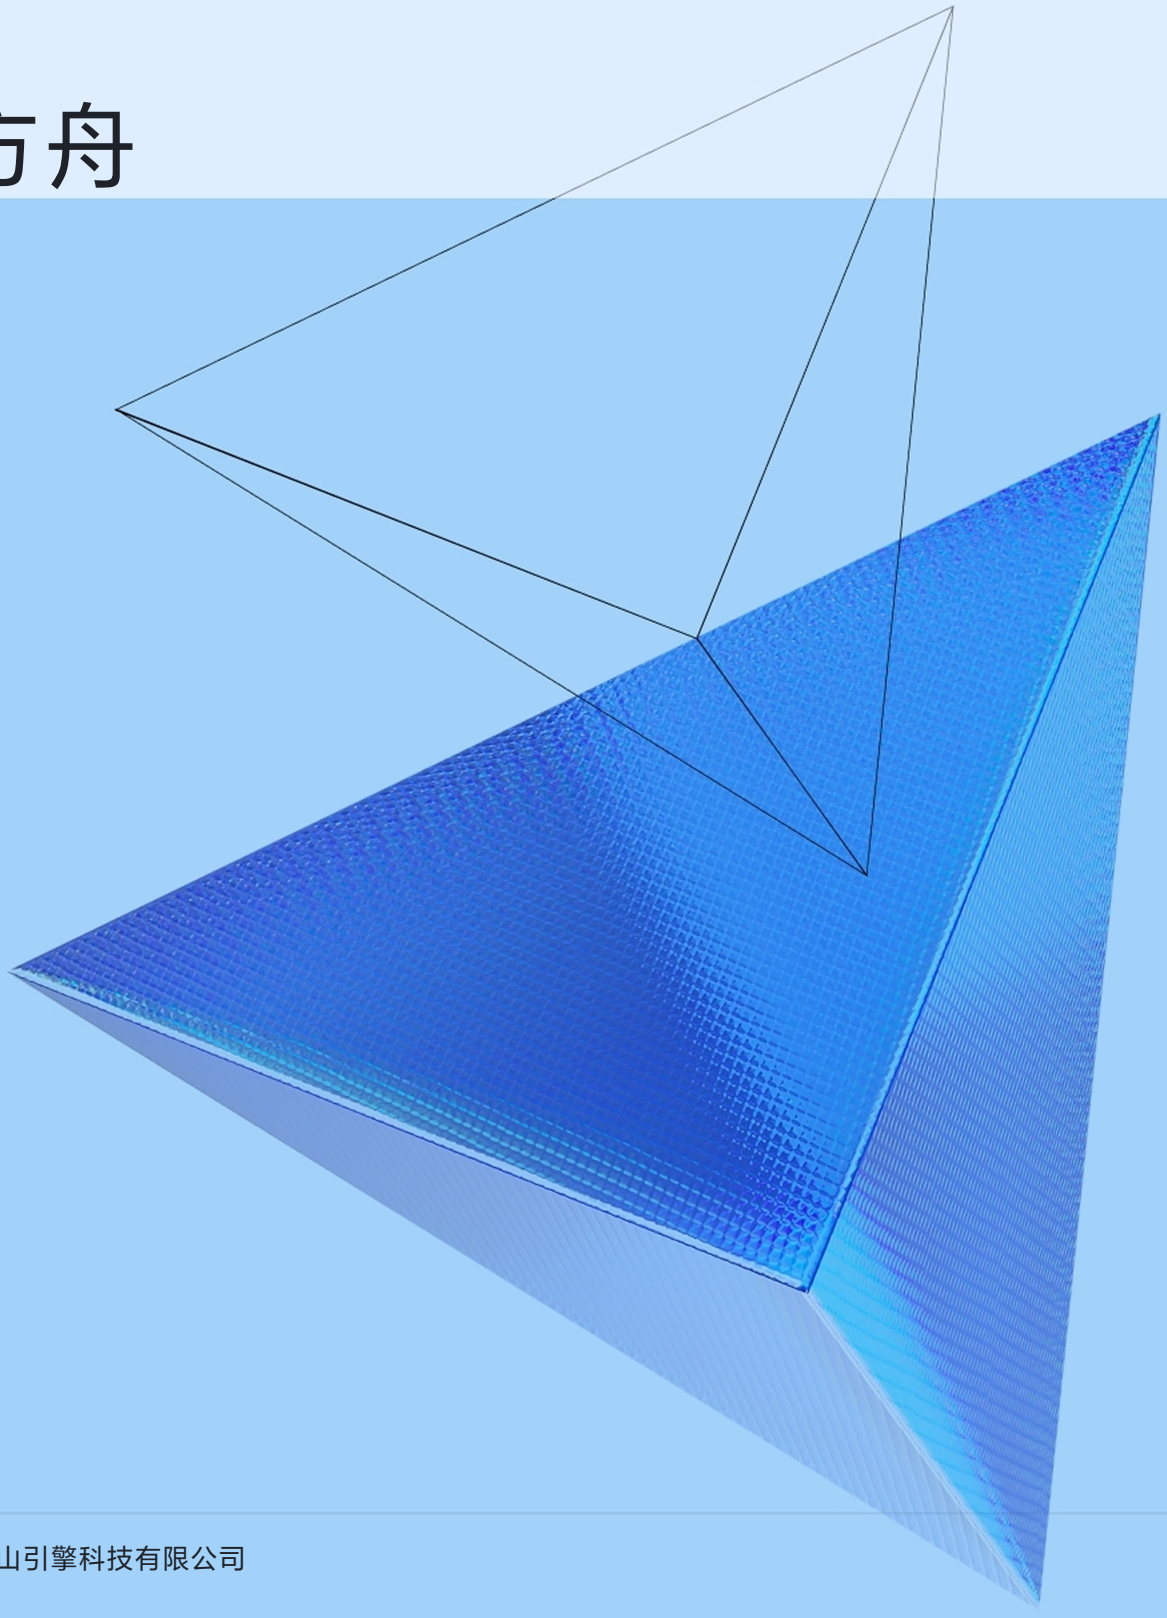
火山引擎

Agent 场景模型调用的正确姿势

火山方舟



版权所有©北京火山引擎科技有限公司

法律声明

本《火山方舟》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《火山方舟》所承载的目的进行传播。

本《火山方舟》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《火山方舟》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《火山方舟》有任何错误或歧义，或发现有对本《火山方舟》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030
（周一至周五 10:00-18:00）

目录

法律声明----------1
目录----------1
1. Agent 场景模型调用的正确姿势----------1

1. Agent 场景模型调用的正确姿势

重要注意事项

在 Agent 场景下，如果出现模型效果不及预期、任务通过率下降、输出被截断或缓存命中率异常等情况，建议优先排查模型调用方式，正确的使用方式 如下：

- **回传思考内容**： 按模型选择支持的回传方式。对需要回传思考内容加密原文的模型， **必须原样回传思考内容加密原文** 。
- **配置关键参数**： 按推荐值配置输出长度参数、thinking 参数、reasoning_effort 参数、temperature 及 top_p 参数。
- **遵循缓存命中原则**： 在同一 Session 内保持采样参数、思考配置、工具定义与 System Prompt 的稳定，避免重置 Prefix Cache。

本文根据 Agent 场景下经常遇到的问题梳理可能原因，并给出推荐的使用方式，便于问题定位并修改。

常见问题	可能的原因	推荐使用方式
多轮工具调用效果随轮数增加而下降	思考内容未回传，导致每一轮工具返回后丢失思考内容	回传思考内容
相同模型、相同 Prompt 在不同实现下任务通过率差异明显	参数配置未按推荐值；上下文回传不完整	配置关键参数 回传思考内容
回答被截断、工具参数 JSON 不完整、`finish_reason` / `stop_reason` 为 `length`	`max_tokens` 未显式传入或值过小	调整输出长度参数
Prompt Cache 命中率异常偏低	System Prompt 或工具定义在轮次间发生变化；Session 内改动参数	遵循缓存命中原则

推荐使用方式

三种接口在字段名、层级与默认返回策略上存在差异，请依据实际使用的接口对照下表进行配置。

维度	Chat API(OpenAI 兼容) `/api/v3/chat/completions`	Responses API `/api/v3/responses`	Anthropic 兼容 API `/api/compatible/v1/messages`
	Doubao 模型：doubao-seed-1-8-251228、doubao-seed-2-0-pro-260215、doubao-seed-2-0-lite-260215、doubao-seed-2-0-		

版权所有©北京火山引擎科技有限公司

<table>
<tr><th>维度</th><th>Chat API(OpenAI 兼容)
<code>/api/v3/chat/completions</code></th><th>Responses API
<code>/api/v3/responses</code></th><th>Anthropic 兼容 API
<code>/api/compatible/v1/messages</code></th></tr>
<tr><td>回传思考内容原文（明文）支持的模型</td><td colspan="3">mini-260215
开源模型：deepseek-v4-pro-260425、deepseek-v4-flash-260425、deepseek-v4-flash-ga-260731、glm-5-2-260617</td></tr>
<tr><td>回传思考内容原文对应的字段

需要将思考内容原文拼回下一轮请求</td><td><code>choices[].message.reasoning_content</code></td><td>· 手动回传：<code>output[reasoning].summary[].text</code>
· 使用 <code>previous_response_id</code> ：配置 <code>store: true</code> ，自动获取原始思考内容</td><td><code>content[thinking].thinking</code></td></tr>
<tr><td>回传思考内容加密原文支持的模型</td><td colspan="3">Doubao 模型：doubao-seed-evolving、doubao-seed-2-1-pro-260628、doubao-seed-2-1-turbo-260628、doubao-seed-2-0-lite-260428

注意
· 使用支持的模型时，需要 回传思考内容加密原文 ，回传时的关键规则及使用示例参见 关键规则、回传思考内容加密块使用示例。模型调用时返回的内容是思考内容加密字段、明文摘要字段，不是思考内容原文。模型真正用于推理的完整思考内容存在于 加密字段 中。仅回传 <code>reasoning_content</code> 等摘要字段并不等同于回传了完整思考内容，会直接导致模型推理效果下降。
· 同一模型的不同版本可能属于不同类别： <code>doubao-seed-2.0-lite-260215</code> 回传思考内容原文(明文)， <code>doubao-seed-2.0-lite-260428</code> 起改为回传思考内容加密块。升级模型版本时，请务必同步更新调用代码，否则回传方式失效，且不会触发 API 报错。</td></tr>
<tr><td>回传思考内容加密原文对应的字段

需要将思考内容加密原文拼回下一轮请求</td><td><code>choices[].message.encrypted_content</code></td><td>· 手动回传：<code>output[reasoning].encrypted_content</code>
· 使用 <code>previous_response_id</code> ：配置 <code>store: true</code> ，自动获取原始思考内容</td><td><code>content[thinking].signature</code></td></tr>
<tr><td>是否默认返回思考内容加密字段</td><td>是</td><td>否，需在 <code>include</code> 中显式声明</td><td>是</td></tr>
</table>

版权所有©北京火山引擎科技有限公司

维度	Chat API(OpenAI 兼容) `/api/v3/chat/completions`	Responses API `/api/v3/responses`	Anthropic 兼容 API `/api/compatible/v1/messages`
		`reasoning.encrypted_content`	
回传思考内容明文摘要对应的字段 > 不能只回传思考内容明文摘要，会导致模型效果下降。	`choices[].message.reasoning_content`	`output[reasoning].summary[].text`	`content[thinking].thinking`
配置输出长度参数	`max_tokens` / `max_completion_tokens` **推荐**： 必须显式传，Agent 场景建议 ≥ `128000`	`max_output_tokens` **推荐**： 必须显式传，Agent 场景建议 ≥ `128000`	`max_tokens` **推荐**： 必须显式传，Agent 场景建议 ≥ `128000`
配置 thinking 参数	`{"type": "enabled"}` **推荐**： Agent 场景下显式开启，不要使用 `auto`	`{"type": "enabled"}` **推荐**： Agent 场景下显式开启，不要使用 `auto`	`{"type": "enabled"}` **推荐**： Agent 场景下显式开启，不要使用 `auto`
配置 reasoning_effort 参数	`"reasoning_effort": "high"` **推荐**： Agent 场景建议 `high` 或以上	`"reasoning": {"effort": "high"}` **推荐**： Agent 场景建议 `high` 或以上	`"output_config": {"effort": "high"}` **推荐**： Agent 场景建议 `high` 或以上
配置 temperature / top_p 参数	**推荐** `temperature=1` 、`top_p=0.95`	**推荐** `temperature=1` 、`top_p=0.95`	**推荐** `temperature=1` 、`top_p=0.95`

> **注意**
>
> 请务必在同一 Session 内保持采样参数、思考配置、工具定义与 System Prompt 的稳定，任何中途修改都会重置 Prefix Cache。

核心机制：思考内容回传

为什么需要回传思考内容

在 Agent 场景中，一个任务通常会经历多轮“推理 -> 调用工具 -> 等待结果 -> 继续推理 -> 调用工具”，工具结果返回后，模型需要继续在该推理链路上把后续步骤做完。
如果不回传思考内容，会有以下影响：

- **推理连续性会被打断**：工具结果返回后，模型只能根据可见对话文本重新构建上下文。对于复杂任务这些隐含的中间判断无法被完整还原，容易出现推理衔接不顺或逻辑断层的情况。
- **多步执行稳定性下降**：由于缺少中间推理状态，模型可能重复做已做过的推导，或者在下一步采用与前一步不一致的假设，导致任务执行跑偏、步骤不稳定，影响结果的一致性与可复现性。
- **整体成本上升**：回传的思考内容会与 tool result 一起参与缓存，更容易命中 Prompt Cache。对包含多次工具调用的场景来说，缓存命中意味着减少重复 token 消耗，从而降低整体成本。

回传方式与支持模型

方舟大模型的思考内容回传方式分为两类：

- **回传思考内容原文（明文）**：将响应中的思考内容原文直接拼回下一轮请求。
- **回传思考内容加密原文**：将响应中的加密原文原样拼回下一轮请求。

两类回传方式支持的模型不同，具体参见 推荐使用方式。

关键规则

- 思考内容加密字段 **要求原样、完整回传**。任何篡改或截断都会返回 `Invalid signature` 错误。
- 不回传思考内容加密原文 **不会触发报错，但会影响推理效果**。
- 思考内容加密字段 **优先级高于思考内容摘要**：同时传入时，明文摘要会被忽略。
- 输出思考内容部分计费会按原始思考内容 token 计算，如果不回传思考内容加密原文，已付费的思考内容不仅没有起到效果，还可能会导致推理效果下降。

其他关键参数配置建议

关键配置	推荐配置	配置错误的影响	自检方式
thinking	Agent 场景显式设置为 `enabled`，不建议使用 `auto`。	`auto` 模式下模型可能判定简单直接回答，多步任务的规划能力因此下降。	观察响应中是否包含思考内容块。
reasoning_effort	Agent 与多步工具调用场景设置为 `high` 或以上。	低档位下思考不足，工具选择与工具参数构造的错误率会上升。	-
temperature 与 top_p	`temperature=1`，`top_p=0.95`	会影响工具调用稳定性和推理质量。	-

关键配置	推荐配置	配置错误的影响	自检方式
		不建议同时大幅调整 `temperature` 与 `top_p`，两者叠加影响难以定位。	
max_tokens	**必须显式传入**，Agent 场景建议 ≥ `128000`。实际取值需结合模型 `max_output_tokens` 上限与业务场景。	回答被截断、工具参数 JSON 不完整、Agent Loop 中断。	观察 `finish_reason` / `stop_reason` 是否为 `length`。
缓存命中率	System Prompt 与工具定义放在请求的最前部，且在同一 Session 内保持稳定不变。 **注意** 导致 Cache 失效的常见操作：修改 `thinking` 配置、修改 `reasoning_effort`、修改采样参数（`temperature`、`top_p` 等）、修改 System Prompt、修改工具定义。	Cache 命中率下降，整体成本上升。	观察响应中 Cache 命中的 token 数。

回传思考内容加密块使用示例

Chat API（OpenAI 兼容）

非流式响应

对于非流式响应，加密块位于 assistant 消息的**扁平字段** `encrypted_content`，与 `reasoning_content`、`tool_calls` 同级。`encrypted_content` 默认返回，无需额外声明。

正确使用方式：将响应中的 assistant message 对象整体加入到下一轮 `messages` 中，避免按字段挑选重建。

```
curl https://ark.cn-beijing.volces.com/api/v3/chat/completions \
  -H "Content-Type: application/json" \
  -H "Authorization: Bearer $ARK_API_KEY" \
  -d '{
    "model": "doubao-seed-evolving",
    "thinking": {"type": "enabled"},
    "temperature": 1,
    "top_p": 0.95,
    "max_tokens": 128000,
    "messages": [
      {"role": "system", "content": "你是人工智能助手。"},
      {"role": "user", "content": "今天是 2026-08-10（星期一）。明天北京天气怎么样？"},
      {
        "role": "assistant",
        "reasoning_content": "用户问明天北京天气，明天是 2026-08-11，调用天气工具。",
        "encrypted_content": "<完整加密块，原样回传>",
        "tool_calls": [
          {
            "id": "call_wiezxeyae8jzxl3jx8nhfgb5",
            "type": "function",
            "function": {"name": "get_weather", "arguments": "{\"location\":\"北京\",\"date\":
\"2026-08-11\"}"}
          }
        ]
      },
      {
        "role": "tool",
        "tool_call_id": "call_wiezxeyae8jzxl3jx8nhfgb5",
        "content": "2026-08-11 北京：阴，11~16° C，北风4级。"
      }
    ],
    "tools": [
      {
        "type": "function",
        "function": {
          "name": "get_weather",
          "description": "查询指定城市指定日期的天气",
          "parameters": {
            "type": "object",
            "properties": {
              "location": {"type": "string", "description": "城市名，如北京、上海"},
              "date": {"type": "string", "description": "日期，格式 YYYY-MM-DD"}
```

```
Bash
        },
        "required": ["location", "date"]
      }
    }
  }
 ]
}'
```

流式响应

流式响应下，思考内容加密块由**独立的 chunk** 下发，时机是思考内容输出完成之后、正式应答开始之前。该 chunk 的 `content` 与 `reasoning_content` **可能均为空**。
正确使用方式：请务必在流式合并逻辑中对 `encrypted_content` 字段做处理。仅处理 `delta.content` 或 `delta.reasoning_content`，会直接导致丢失思考内容加密块，从而影响推理效果。

```
Bash
curl https://ark.cn-beijing.volces.com/api/v3/chat/completions \
 -H "Content-Type: application/json" \
 -H "Authorization: Bearer $ARK_API_KEY" \
 -d '{
  "model": "doubao-seed-evolving",
  "stream": true,
  "thinking": {"type": "enabled"},
  "max_tokens": 128000,
  "messages": [
   {"role": "user", "content": "今天是 2026-08-10。明天北京天气怎么样？"}
  ]
}'
```

响应片段（示意）：

```
text
data: {"choices":[{"delta":{"reasoning_content":"用户问明天"}}]}
data: {"choices":[{"delta":{"reasoning_content":"北京天气…"}}]}
data: {"choices":[{"delta":{"content":"","reasoning_content":"","encrypted_content":"<完整加密块>"}}]}
data: {"choices":[{"delta":{"content":"明天北京"}}]}
data: [DONE]
```

Responses API

非流式响应

对于非流式响应，加密块位于 `output` 数组内 `type == "reasoning"` 的 item。
回传思考内容加密块的方式如下：

- **previous_response_id**：**注意需显式配置 ** `store: true` 。由服务端托管 session 状态，客户端无需自行搬运历史 item，自动获取思考内容加密块并回传给模型参与推理。
- **手动回传思考内容加密块**：**必须显式在 ** `include` ** 中声明 ** `reasoning.encrypted_content` ，否则响应中不会返回加密块。

手动回传思考内容加密块注意事项：

- Reasoning item 的 `id` 必须原样带回，不能自行生成。
- 回放时 `content` 可以是空数组 `[]` ，但 `encrypted_content` **不能为空**。
- 连续多次工具调用时，从最后一条 user message 之后的所有 item（ `reasoning` / `function_call` / `function_call_output` ）必须按原顺序全部带回，不能只带最后一个。

手动回传思考内容加密块的示例如下：

```
curl https://ark.cn-beijing.volces.com/api/v3/responses \
  -H "Content-Type: application/json" \
  -H "Authorization: Bearer $ARK_API_KEY" \
  -d '{
    "model": "doubao-seed-evolving",
    "store": false,
    "include": ["reasoning.encrypted_content"],
    "reasoning": {"effort": "high", "summary": "detailed"},
    "max_output_tokens": 128000,
    "input": [
      {"type": "message", "role": "user", "content": "今天是 2026-08-10（星期一）。明天天气怎么样？"},
      {
        "id": "rs_0c2e0389c1bdc80f016a79c44c1fd08198bbdcb852ca75789b",
        "type": "reasoning",
        "content": [],
        "encrypted_content": "<完整加密块，原样回传>",
        "summary": [
          {"type": "summary_text", "text": "先取用户所在城市，再查 2026-08-11 的天气。"}
        ]
      },
      {
        "id": "fc_0c2e0389c1bdc80f016a79c44d9fac81988abe3597d1fbba88",
        "type": "function_call",
        "status": "completed",
        "call_id": "call_tjOpXT7tq4KbtdnpQYdBNTXz",
        "name": "get_location",
        "arguments": "{\"location_level\":\"city\"}"
      },
      {
```

```
    "type": "function_call_output",
    "call_id": "call_tjOpXT7tq4KbtdnpQYdBNTXz",
    "output": "北京"
   },
   {
    "id": "fc_0c2e0389c1bdc80f016a79c451d4348198a1c4eb858f8a858b",
    "type": "function_call",
    "status": "completed",
    "call_id": "call_cf3Sz3cE2fZkZBPdez5P9Ecb",
    "name": "get_weather",
    "arguments": "{\"location\":\"北京\",\"date\":\"2026-08-11\"}"
   },
   {
    "type": "function_call_output",
    "call_id": "call_cf3Sz3cE2fZkZBPdez5P9Ecb",
    "output": "2026-08-11 北京： 阴，11~16° C，北风4级。"
   }
  ],
  "tools": [
   {
    "type": "function",
    "name": "get_location",
    "description": "获取用户当前位置",
    "parameters": {
     "type": "object",
     "properties": {
      "location_level": {"type": "string", "description": "所需粒度： country / province / city / street"}
     },
     "required": ["location_level"],
     "additionalProperties": false
    },
    "strict": true
   },
   {
    "type": "function",
    "name": "get_weather",
    "description": "查询指定城市指定日期的天气",
    "parameters": {
     "type": "object",
     "properties": {
      "location": {"type": "string", "description": "城市名"},
      "date": {"type": "string", "description": "日期，格式 YYYY-MM-DD"}
     },
     "required": ["location", "date"],
     "additionalProperties": false
    },
    "strict": true
```

```
Bash }
    ]
  }'
```

流式响应

对于流式响应，思考内容加密块通过 `response.output_item.added` / `response.output_item.done` / `response.completed` 等相关事件下发，需要按事件中 **encrypted_content** 字段非空过滤，并获取思考内容加密加密原文。
获取到思考内容加密块后，回传方式参考上述示例。

Anthropic 兼容 API

加密内容位于 assistant content 数组中 `type == "thinking"` 的块的 **`signature`** 字段（Anthropic 协议原生命名）。
正确使用方式：

- thinking 块必须**整块回传**（ `thinking` 文本 + `signature` 一起），并保持在 `tool_use` 块**之前**的原始顺序。
- **请勿按 ** `type == "thinking"` ** 做白名单过滤后重新构造 content 数组**。顺序或块被改动会导致校验失败。

```
curl https://ark.cn-beijing.volces.com/api/v3/compatible/v1/messages \
  -H "Content-Type: application/json" \
  -H "x-api-key: $ARK_API_KEY" \
  -H "anthropic-version: 2023-06-01" \
  -d '{
    "model": "doubao-seed-evolving",
    "max_tokens": 128000,
    "thinking": {"type": "enabled"},
    "messages": [
      {"role": "user", "content": "今天是 2026-08-10（星期一）。明天天气怎么样？"},
      {
        "role": "assistant",
        "content": [
          {
            "type": "thinking",
            "thinking": "用户问明天天气，明天是 2026-08-11。需要先获取城市，再查天气。",
            "signature": "<完整加密块，原样回传>"
          },
          {
            "type": "tool_use",
            "id": "tool_4U01J2huMeLhTITKyrU5rhI5",
            "name": "get_location",
            "input": {"location_level": "city"}
```

```Bash
        }
       ]
      },
      {
       "role": "user",
       "content": [
        {
         "type": "tool_result",
         "tool_use_id": "tool_4U01J2huMeLhTlTKyrU5rhI5",
         "content": "北京"
        }
       ]
      }
     ],
     "tools": [
      {
       "name": "get_location",
       "description": "获取用户当前位置",
       "input_schema": {
        "type": "object",
        "properties": {
         "location_level": {"type": "string", "description": "所需粒度： country / province / city / street"}
        },
        "required": ["location_level"]
       }
      },
      {
       "name": "get_weather",
       "description": "查询指定城市指定日期的天气",
       "input_schema": {
        "type": "object",
        "properties": {
         "location": {"type": "string", "description": "城市名"},
         "date": {"type": "string", "description": "日期，格式 YYYY-MM-DD"}
        },
        "required": ["location", "date"]
       }
      }
     ]
    }'
```