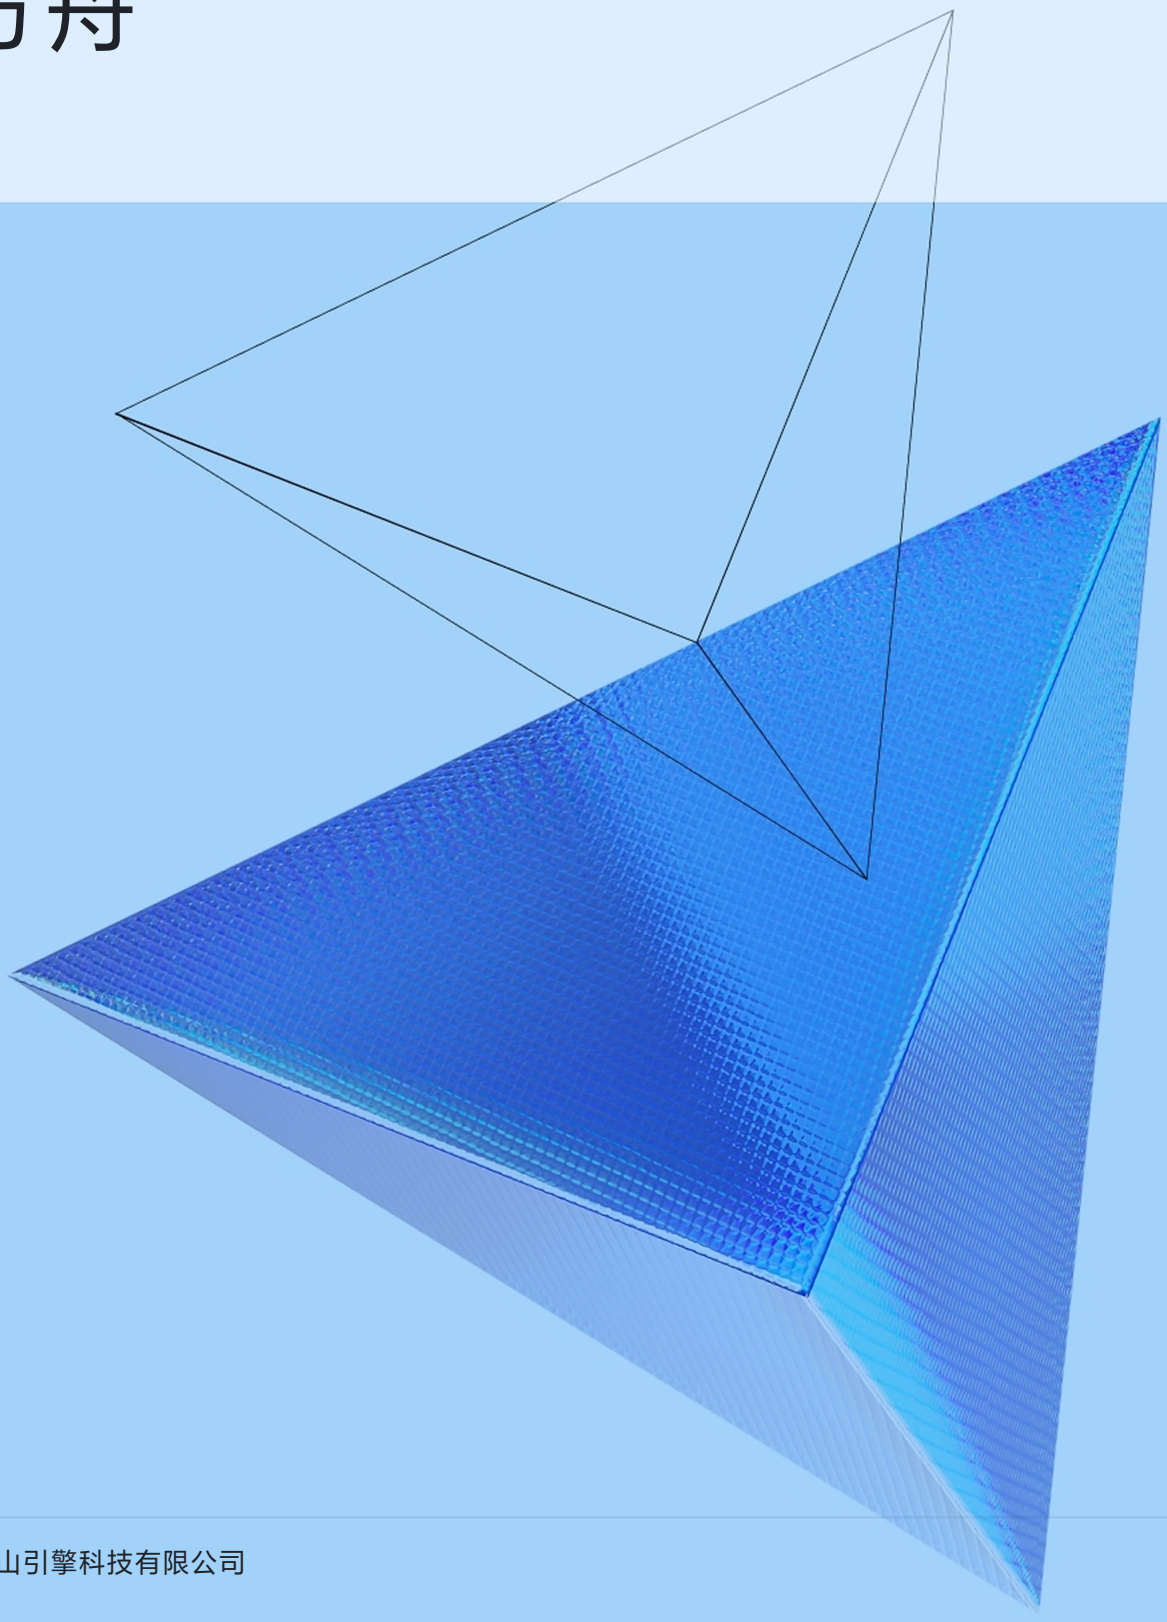
火山引擎

对话(Chat) API

火山方舟



版权所有©北京火山引擎科技有限公司

法律声明

本《火山方舟》的所有内容，包括但不限于文字、商标、架构、图示、图片、页面布局等，其知识产权（著作权、商标权、专利权、商业秘密等）归属于北京火山引擎科技有限公司及其关联公司（火山引擎），非经火山引擎书面同意，任何个人和组织不得复制、使用、修改、转发或以任何违反本《火山方舟》所承载的目的进行传播。

本《火山方舟》陈述内容仅作为产品的通用性介绍和参考性指引，火山引擎保留按“现状”和“当前可用”的形式提供产品和服务的权利。火山引擎不对本《火山方舟》中所载的产品功能、性质、质量、标准等内容进行明示或默示的保证和承诺，最终以您与火山引擎实际签署的协议为准。

如您发现本《火山方舟》有任何错误或歧义，或发现有对本《火山方舟》、产品本身的侵权行为，请与火山引擎取得联系。

联系方式：service@volcengine.com，400-850-0030
（周一至周五 10:00-18:00）

目录

法律声明----------1
目录----------1
1. 对话(Chat) API----------1

1. 对话(Chat) API

POST https://ark.cn-beijing.volces.com/api/v3/chat/completions
发送包含文本、图片、视频、音频等模态的消息列表，模型将生成对话中的下一条消息。

鉴权

本接口支持鉴权方式如下，详情请参见 Base URL 及鉴权。

- 【推荐】API Key 鉴权，请在 API Key 管理 页面，获取长效 API Key。
- 【可选】Access Key 鉴权，请在 Access Key 管理 页面，获取 Access Key。

请求参数

Body 参数

messages object[] 必选 | 消息列表
不同模型支持不同类型的消息，如文本、图片、视频、音频等

系统消息 object
系统消息，模型需遵循的指令，包括扮演的角色、背景信息等。

content string / object[] 必选 | 消息内容
messages.content
系统消息的内容，支持纯文本或多模态内容

纯文本 string
纯文本内容

多模态内容 object[]
多模态内容，支持文本、图片、视频、音频等模态内容。

文本信息 object
文本部分，多模态消息中文本模态的部分。

text string 必选 | 文本内容
messages.content.text
文本模态部分的内容

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 text

图片信息 object
图片部分

image_url object 必选 | 图片内容
messages.content.image_url
图片模态的内容。 图片输入支持 **file_id**、**url** 两个字段，需二选一传入。具体使用请参见 图片理解说明

url string 必选 | 资源 URL
messages.content.image_url.url
发给模型的图片 URL。支持格式如下：

- 图片链接
- 图片的 Base64 编码

detail string | 图片解析粒度
messages.content.image_url.detail
图片解析粒度。
理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见 控制图片理解的精细度。可选值： low 、 high 、 xhigh 。

file_id string | 文件 ID
messages.content.image_url.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
>
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
>
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

image_pixel_limit object 默认值 null | 图片像素限制
messages.content.image_url.image_pixel_limit
输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

- 生效优先级：高于 **detail** 字段，即同时配置 **detail** 与 **image_pixel_limit** 字段时，生效 **image_pixel_limit** 字段配置。
- 默认生效规则：若未设置 **image_pixel_limit** ，则使用 **detail** 配置的值对应的 **min_pixels** / **max_pixels** 值。

> **注意**
>
> 图片像素范围需在 [196, 36,000,000]，否则会直接报错。

max_pixels integer | 最大像素
messages.content.image_url.image_pixel_limit.max_pixels
传入图片最大像素限制，大于此像素则等比例缩小至 max_pixels 字段取值以下。若未设置，则取值为 detail 配置的值对应的 max_pixels 值。
模型支持：

- **doubao-seed-1.8 之前的模型**： 最大值 4014080
- **doubao-seed-1.8、doubao-seed-2.0 模型**： 最大值 9031680

min_pixels integer | 最小像素
messages.content.image_url.image_pixel_limit.min_pixels
传入图片最小像素限制，小于此像素则等比例放大至 min_pixels 字段取值以上。若未设置，则取值为 detail 配置的值对应的 min_pixels 值。
模型支持：

- **doubao-seed-1.8 之前的模型**： 最小值 3136
- **doubao-seed-1.8、doubao-seed-2.0 模型**： 最小值 1764

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 image_url

视频信息 object
视频部分

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 video_url

video_url object 必选 | 视频内容
messages.content.video_url
视频消息的内容部分。 视频输入支持 **file_id**、**url** 两个字段，需二选一传入。具体使用请参见 视频理解说明

url string 必选 | 资源 URL
messages.content.video_url.url
发给模型的视频 URL。支持格式如下：

- 视频链接
- 视频的 Base64 编码

file_id string | 文件 ID
messages.content.video_url.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
>
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
>
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

版权所有©北京火山引擎科技有限公司

fps number 默认值 1.0 | 视频帧率
messages.content.video_url.fps
抽帧频率，详见 视频理解 。

- 取值越高，对视频中画面变化越敏感。
- 取值越低，对视频中画面变化越迟钝，但 token 花费少，速度更快。

取值范围： [0.2, 5]

音频信息 object
音频部分

input_audio object 必选 | 音频内容
messages.content.input_audio
音频模态的内容。 音频输入支持 **file_id**、**url**、**data** 三个字段，需三选一传入。具体使用请参见 音频理解

> **注意**
> - 文件大小不超过 25 MB。
> - 单次请求音频总时长不超过 120 分钟，仅统计纯音频时长，视频内嵌音频不计入统计。
> - 详细说明请参见 音频理解 。

data string | 音频数据
messages.content.input_audio.data
音频内容的 Base64 编码

file_id string | 文件 ID
messages.content.input_audio.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

format string | 音频格式
messages.content.input_audio.format
音频格式。当使用 **data** 时，该参数必填。支持的音频格式 MIME 类型如下： 纯音频格式：

- mp3： audio/mpeg
- wav： audio/wav
- aac： audio/aac

版权所有©北京火山引擎科技有限公司

- m4a： audio/mp4
  视频内嵌音频格式：
- mp3： audio/mpeg
- wav： audio/wav
- aac： audio/aac
- m4a： audio/mp4
- pcm： audio/L16
- ac3： audio/ac3
- alac： audio/mp4

url string | 资源 URL
messages.content.input_audio.url
音频内容的 URL

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 input_audio

文件信息 object
文件部分

file object 必选 | 文件内容
messages.content.file
文件模态的内容，当前仅支持 PDF 文件。 文件输入支持 **file_id**、**file_data**、**file_url** 三个字段，需三选一传入。多模态理解示例见 文档理解

> **说明**
>
> 文档理解详细说明请参见 文档理解。

file_data string | 文件数据
messages.content.file.file_data
文件内容的 Base64 编码。单个文件大小要求不超过 50 MB

file_id string | 文件 ID
messages.content.file.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
>
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
>
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

file_url string | 资源 URL
messages.content.file.file_url
文件的可访问 URL。对应文件的大小要求不超过 50 MB

filename string | 文件名
messages.content.file.filename
文件名。当使用 **file_data** 时该参数必填

type string 必选 | 类型
messages.content.type
消息模态，此处固定为 file

role string 必选 | 角色
messages.role
发送消息的角色，取值固定为 system 。

name string | 参与者名称
messages.name
参与者名称，帮助模型区分不同的参与者

用户消息 object
用户消息，用户角色发送的消息。不同模型支持的字段类型不同。

content string / object[] 必选 | 消息内容
messages.content
用户消息的内容，支持纯文本或多模态内容

纯文本 string
纯文本内容

多模态内容 object[]
多模态内容，支持文本、图片、视频、音频等模态内容。

文本信息 object
文本部分，多模态消息中文本模态的部分。

text string 必选 | 文本内容
messages.content.text
文本模态部分的内容

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 text

图片信息 object
图片部分

image_url object 必选 | 图片内容
messages.content.image_url
图片模态的内容。 图片输入支持 **file_id**、**url** 两个字段，需二选一传入。具体使用请参见 图片理解说明

url string 必选 | 资源 URL
messages.content.image_url.url
发给模型的图片 URL。支持格式如下：

- 图片链接
- 图片的 Base64 编码

detail string | 图片解析粒度
messages.content.image_url.detail
图片解析粒度。
理解图片的精细度、不同模型默认取值及对应的具体像素区间，参见 控制图片理解的精细度。可选值： low 、 high 、 xhigh 。

file_id string | 文件 ID
messages.content.image_url.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
>
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
>
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

image_pixel_limit object 默认值 null | 图片像素限制
messages.content.image_url.image_pixel_limit
输入给模型的图片的像素范围，如不在此范围，图片会被等比例缩放至该范围。

- 生效优先级：高于 **detail** 字段，即同时配置 **detail** 与 **image_pixel_limit** 字段时，生效 **image_pixel_limit** 字段配置。
- 默认生效规则：若未设置 **image_pixel_limit** ，则使用 **detail** 配置的值对应的 **min_pixels** / **max_pixels** 值。

> **注意**
>
> 图片像素范围需在 [196, 36,000,000]，否则会直接报错。

max_pixels integer | 最大像素
messages.content.image_url.image_pixel_limit.max_pixels
传入图片最大像素限制，大于此像素则等比例缩小至 max_pixels 字段取值以下。若未设置，则取值为 detail 配置的值对应的 max_pixels 值。
模型支持：

- **doubao-seed-1.8 之前的模型**： 最大值 4014080
- **doubao-seed-1.8、doubao-seed-2.0 模型**： 最大值 9031680

min_pixels integer | 最小像素
messages.content.image_url.image_pixel_limit.min_pixels
传入图片最小像素限制，小于此像素则等比例放大至 min_pixels 字段取值以上。若未设置，则取值为 detail 配置的值对应的 min_pixels 值。
模型支持：

- **doubao-seed-1.8 之前的模型**： 最小值 3136
- **doubao-seed-1.8、doubao-seed-2.0 模型**： 最小值 1764

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 image_url

视频信息 object
视频部分

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 video_url

video_url object 必选 | 视频内容
messages.content.video_url
视频消息的内容部分。 视频输入支持 **file_id**、**url** 两个字段，需二选一传入。具体使用请参见 视频理解说明

url string 必选 | 资源 URL
messages.content.video_url.url
发给模型的视频 URL。支持格式如下：

- 视频链接
- 视频的 Base64 编码

file_id string | 文件 ID
messages.content.video_url.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
>
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
>
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

fps number 默认值 1.0 | 视频帧率
messages.content.video_url.fps
抽帧频率，详见 视频理解。

- 取值越高，对视频中画面变化越敏感。
- 取值越低，对视频中画面变化越迟钝，但 token 花费少，速度更快。

取值范围： [0.2, 5]

音频信息 object
音频部分

input_audio object 必选 | 音频内容
messages.content.input_audio
音频模态的内容。 音频输入支持 **file_id**、**url**、**data** 三个字段，需三选一传入。具体使用请参见 音频理解

> **注意**
> - 文件大小不超过 25 MB。
> - 单次请求音频总时长不超过 120 分钟，仅统计纯音频时长，视频内嵌音频不计入统计。
> - 详细说明请参见 音频理解。

data string | 音频数据
messages.content.input_audio.data
音频内容的 Base64 编码

file_id string | 文件 ID
messages.content.input_audio.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

format string | 音频格式
messages.content.input_audio.format
音频格式。当使用 **data** 时，该参数必填。支持的音频格式 MIME 类型如下： 纯音频格式：

- mp3： audio/mpeg
- wav： audio/wav
- aac： audio/aac

版权所有©北京火山引擎科技有限公司

- m4a： audio/mp4
  视频内嵌音频格式：
- mp3： audio/mpeg
- wav： audio/wav
- aac： audio/aac
- m4a： audio/mp4
- pcm： audio/L16
- ac3： audio/ac3
- alac： audio/mp4

url string | 资源 URL
messages.content.input_audio.url
音频内容的 URL

type string 必选 | 类型
messages.content.type
内容模态类型，此处固定为 input_audio

文件信息 object
文件部分

file object 必选 | 文件内容
messages.content.file
文件模态的内容，当前仅支持 PDF 文件。 文件输入支持 **file_id**、**file_data**、**file_url** 三个字段，需三选一传入。多模态理解示例见 文档理解

> **说明**
>
> 文档理解详细说明请参见 文档理解。

file_data string | 文件数据
messages.content.file.file_data
文件内容的 Base64 编码。单个文件大小要求不超过 50 MB

file_id string | 文件 ID
messages.content.file.file_id
文件 ID。

- 文件 ID 是通过 Files API 上传文件后返回的 id。
- **file_id** 对应的文件类型需要和 **type** 保持一致，且文件状态需要为 **active** 。
- **API Key** 所属项目与 **file_id** 上传时所属项目需保持一致

> **注意**
>
> Chat API 支持通过 **file_id** 传入火山引擎 TOS Bucket 中的文件，支持该能力的模型范围如下：
>
> - doubao-seed-2.0-mini 系列：doubao-seed-2-0-mini-260428 及后续版本。
> - doubao-seed-2.0-lite 系列：全版本支持。
> - doubao-seed-2.0-pro 系列：全版本支持。

file_url string | 资源 URL
messages.content.file.file_url
文件的可访问 URL。对应文件的大小要求不超过 50 MB

filename string | 文件名
messages.content.file.filename
文件名。当使用 **file_data** 时该参数必填

type string 必选 | 类型
messages.content.type
消息模态，此处固定为 file

role string 必选 | 角色
messages.role
发送消息的角色，取值固定为 user 。

name string | 参与者名称
messages.name
参与者名称，帮助模型区分不同的参与者

模型消息 object
模型消息，历史对话中模型角色返回的消息。用以保持对话一致性，多在 多轮对话 及 续写模式 使用。

role string 必选 | 角色
messages.role
发送消息的角色，取值固定为 assistant 。

content string | 消息内容
messages.content
模型消息的内容。

> **说明**
> messages.content 与 messages.tool_calls 至少填写其一。

encrypted_content string | 加密思考内容
messages.encrypted_content
思考内容加密原文。经加密及压缩处理后的思考内容加密原文。
在支持的模型调用时，必须回传思考内容加密原文，保证模型推理效果。
相关文档：

- 关键规则
- 回传思考内容加密块使用示例

> **注意**
> - 回传 encrypted_content 内容需有效，篡改或无法还原时返回错误： Invalid signature 。
> - encrypted_content 优先级高于 reasoning_content ，回传 encrypted_content 时，将忽略 reasoning_content 内容。

模型支持：

- doubao-seed-2-0-lite-260428 及后续版本

name string | 参与者名称
messages.name
参与者名称，帮助模型区分不同的参与者

reasoning_content string | 思维链内容
messages.reasoning_content
模型消息中思维链内容。
模型支持：

- doubao-seed-1.8 及后续模型
- deepseek-v4-pro
- deepseek-v4-flash
- deepseek-v3.2

tool_calls object[] | 工具调用
messages.tool_calls
模型消息中工具调用部分

function object 必选 | 函数信息
messages.tool_calls.function
模型调用的函数

arguments string 必选 | 函数参数
messages.tool_calls.function.arguments
模型生成的用于调用函数的参数，JSON 格式。 模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效

name string 必选 | 函数名
messages.tool_calls.function.name
模型调用的函数名称

id string 必选 | ID
messages.tool_calls.id
调用的工具的 ID

type string 必选 | 类型
messages.tool_calls.type
工具类型，当前仅支持 function

工具消息 object
工具消息，历史对话中调用工具返回的消息。工具调用场景中使用。

content string 必选 | 消息内容
messages.content
工具返回的消息。

role string 必选 | 角色
messages.role
发送消息的角色，取值固定为 tool 。

tool_call_id string 必选 | 工具调用 ID
messages.tool_call_id
模型生成的需调用工具请求时，生成的 ID。在程序调用工具的返回需要附上同一 ID，来关联工具结构与模型请求。避免多工具调用时混淆信息

name string | 参与者名称
messages.name
参与者名称，帮助模型区分不同的参与者

model string 必选 | 模型 ID
调用的模型 ID（Model ID）。开通模型服务 后可 查询 Model ID 。
多个应用及精细管理场景，推荐使用推理接入点 ID 调用，详细请参考 获取 Endpoint ID 。

frequency_penalty number 默认值 0.0 | 频率惩罚系数
如值为正，根据新 token 在文本中的出现频率对其进行惩罚，从而降低模型逐字重复的可能性。
取值范围： [-2.0, 2.0]
不支持模型：

- doubao-seed-1.8 及后续系列

logit_bias object 默认值 null | Token 偏差
调整指定 token 在模型输出内容中出现的概率，使模型生成的内容更加符合特定的偏好。
logit_bias 接受一个 map。每个键为词表中的 token ID（可通过 tokenization 接口获取），每个值为该 token 的偏差值：

- 负值降低选择该 token 的可能性；-100 会完全禁止选择该 token。
- 正值增加选择该 token 的可能性；100 会导致仅可选择该 token。

示例：{"<Token_ID>": -100} 。该参数的实际效果可能因模型而异。

> **注意**
> 带深度思考能力模型不支持该字段，深度思考能力模型参见 文档 。

取值范围： [-100, 100]

logprobs boolean 默认值 false | 返回对数概率
是否返回输出 tokens 的对数概率。

- false：不返回对数概率信息。
- true：返回消息内容中每个输出 token 的对数概率。

> **注意**
> 带深度思考能力模型不支持该字段，深度思考能力模型参见 文档 。

max_completion_tokens integer | 最大输出长度
控制模型输出的最大长度（包括模型回答和模型思维链内容长度，单位 token）。
配置了该参数后，可以让模型输出超长内容，max_tokens 默认值失效，模型按需输出内容（回答和思维链），直到达到 max_completion_tokens 值。
不可与 max_tokens 字段同时设置。

> **注意**
>
> 支持该字段的模型及使用说明见 文档。

取值范围： [1, 65536]

max_tokens integer 默认值 4096 | 最大回答长度
模型回答最大长度（单位 token）。取值范围各个模型不同，详细见 模型列表。

> **说明**
>
> · 模型回答不包含思维链内容，模型回答 = 模型输出 − 模型思维链（如有）
> · 输出 token 的总长度还受模型的上下文长度限制。

parallel_tool_calls boolean 默认值 true | 并行工具调用
本次请求，模型返回是否允许包含多个待调用的工具。

· true：允许返回多个待调用的工具。
· false：允许返回的待调用的工具小于等于 1。

模型支持：

· **doubao-seed-1.6**：及之后系列模型；仅当 parallel_tool_calls=false 时该值受模型支持限制，true 全模型通用

presence_penalty number 默认值 0.0 | 存在惩罚系数
如果值为正，会根据新 token 到目前为止是否出现在文本中对其进行惩罚，从而增加模型谈论新主题的可能性。
取值范围： [−2.0, 2.0]
不支持模型：

· doubao-seed-1.8 及后续系列

reasoning_effort string | 思考深度
限制思考的工作量。减少思考深度可提升速度，思考花费的 token 更少。

· none：关闭思考。
· minimal：关闭思考，直接回答。
· low：轻量思考，侧重快速响应。
· medium：均衡模式，兼顾速度与深度。
· high：深度分析，处理复杂问题。
· xhigh：更高程度思考。
· max：最高程度思考，适配高难度推理任务。

> **说明**
>
> 支持该字段的模型、默认取值、参数兼容映射规则，以及与 thinking.type 字段的关系，详见 文档。

版权所有©北京火山引擎科技有限公司

response_format object | 回答格式
指定模型回答格式。默认值： {"type": "text"}

> **注意**
> · 支持该字段的模型请参见 文档。
> · 该能力尚在 beta 阶段，请谨慎在生产环境使用。

json_schema object | Schema 配置
response_format.json_schema
JSON 结构体的定义

name string 必选 | Schema 名称
response_format.json_schema.name
JSON Schema 的名称，用于标识本次响应格式

schema object 必选 | Schema 定义
response_format.json_schema.schema
回答格式的 JSON Schema 定义

description string | 描述
response_format.json_schema.description
回答用途说明，模型据此判断如何按该格式生成回答

strict boolean 默认值 false | 严格模式
response_format.json_schema.strict
是否在生成输出时，启用严格遵循模式。

· true ：模型将始终严格遵循 schema 字段中定义的格式。
· false ：模型会尽可能遵循 schema 字段中定义的结构。

type string | 类型
response_format.type
回答格式类型。可选值： text 、 json_schema 、 json_object 。

service_tier string 默认值 auto | 推理模式
控制使用的在线推理模式。

· fast ：本次请求优先使用 在线推理（低延迟） 模式。
  ◦ 推理接入点（ model 字段指定）有低延迟限流配额，本次请求将会优先使用低延迟限流配额，获得更高的服务等级（延迟、可用性等）。
  ◦ 推理接入点无低延迟限流配额，或者限流配额已满，降级至 **在线推理（常规）** 模式，维持常规的服务等级。

· auto ：本次请求优先使用 在线推理（TPM 保障包） 模式。
  ◦ 推理接入点有 TPM 保障包额度，本次请求将会优先使用 TPM 保障包额度，获得最高的服务等级。
  ◦ 推理接入点无 TPM 保障包额度或用超额度，降级至 **在线推理（常规）** 模式，维持常规的服务等级。

· default ：本次请求只使用 在线推理（常规） 模式。维持常规的服务等级，即使调用的推理接入点有 TPM 保障包额度 / 低延迟限流额度。

stop string / string[] 默认值 null | 停止词
模型遇到 stop 字段所指定的字符串时将停止继续生成，这个词语本身不会输出。最多支持 4 个字符串。
示例： ["你好", "天气"] 。

> **注意**
> 深度思考能力模型不支持该字段。

stream boolean 默认值 false | 流式返回
响应内容是否流式返回。

- false ：模型生成完所有内容后一次性返回结果。
- true ：按 SSE 协议逐块返回模型生成内容，并以一条 data: [DONE] 消息结束。当 stream 为 true 时，可设置 stream_options 字段以获取 token 用量统计信息。

stream_options object 默认值 null | 流式选项
流式响应的选项。当 stream 为 true 时，可设置本字段。

chunk_include_usage boolean 默认值 false | 逐块用量信息
stream_options.chunk_include_usage
模型流式输出时，输出的每个 chunk 中是否输出本次请求到此 chunk 输出时刻的累计 token 用量信息。

- true ：在返回的 usage 字段中，输出本次请求到此 chunk 输出时刻的累计 token 用量。
- false ：不在每个 chunk 都返回 token 用量信息。

include_usage boolean 默认值 false | 输出用量信息
stream_options.include_usage
模型流式输出时，是否在输出结束前输出本次请求的 token 用量信息。

- true ：在 data: [DONE] 消息之前会返回一个额外的 chunk。此 chunk 中， usage 字段中输出整个请求的 token 用量， choices 字段为空数组。
- false ：输出结束前，没有一个 chunk 来返回 token 用量信息。

temperature number 默认值 1.0 | 采样温度
控制了生成文本时对每个候选词的概率分布进行平滑的程度。当取值为 0 时模型仅考虑对数概率最大的一个 token。
较高的值（如 0.8）会使输出更加随机，而较低的值（如 0.2）会使输出更加集中确定。
通常建议仅调整 temperature 或 top_p 其中之一，不建议两者都修改。

> **注意**
> 调用下列模型时字段取值固定为 1 ，手动指定的参数值将被忽略：
>
> - doubao-seed-2-0-pro-260215
> - doubao-seed-2-0-lite-260215

取值范围： [0, 2]

thinking object | 深度思考开关
控制模型是否开启深度思考模式。

版权所有©北京火山引擎科技有限公司

> **注意**
>
> 不同模型是否支持以及默认取值不同，详情请查询 文档。

type string | 类型
thinking.type
控制模型是否开启思考模式。

- enabled：开启思考模式，模型强制先思考再回答。
- disabled：关闭思考模式，模型直接回答问题，不进行思考。
- auto：自动思考模式，模型根据问题自主判断是否需要思考，简单题目直接回答。

tool_choice string / object | 工具调用控制
本次请求，模型返回信息中是否有待调用的工具。

- none：模型不会调用工具，直接生成消息。当没有指定工具时，none 是默认值。
- auto：模型可以选择生成消息或调用工具。如果存在工具，则 auto 是默认值。
- required：模型必须调用一个或多个工具。

您也可以通过设置 tool_choice 为 object 类型，来强制模型调用指定工具。
模型支持：

- doubao-seed-1.6 及之后系列

枚举值 string
控制模型返回是否包含待调用的工具。

- none：模型返回信息中不可含有待调用的工具。
- required：模型返回信息中必须含待调用的工具。选择此项时请确认存在适合的工具，以减少模型产生幻觉的情况。
- auto：模型自行判断返回信息是否有待调用的工具。

指定工具 object
指定待调用工具的范围。模型返回信息中，只允许包含以下模型信息。
选择此项时请确认该工具适合用户需求，以减少模型产生幻觉的情况。

function object 必选 | 函数信息
tool_choice.function
调用工具的信息

name string 必选 | 函数名
tool_choice.function.name
要调用的函数名称

type string 必选 | 类型
tool_choice.type
调用的类型，此处应为 function

tools object[] 默认值 null | 工具列表
待调用工具的列表，模型返回信息中可包含。
当您需要让模型返回待调用工具时，需要配置该结构体。支持该字段的模型请参见 文档。

版权所有©北京火山引擎科技有限公司

function object 必选 | 函数信息
tools.function
模型返回中可包含待调用的工具

name string 必选 | 函数名
tools.function.name
工具（函数）名称，供模型识别与调用

description string | 描述
tools.function.description
调用的函数的描述，大模型会使用它来判断是否调用这个工具

parameters object | 参数定义
tools.function.parameters
函数请求参数，以 JSON Schema 格式描述。具体格式请参考 JSON Schema 文档。
格式如下：

```JSON
{"type": "object", "properties": {"参数名": {"type": "string | number | boolean | object | array",
"description": "参数说明"}}, "required": ["必填参数"]}
```

使用要点：所有字段名大小写敏感； parameters 须是合规的 JSON Schema 对象；建议用英文字段名，中文置于 description 字段中。

strict boolean | 严格模式
tools.function.strict
是否启用严格的 Schema 校验，确保模型生成的函数调用参数严格符合 parameters 定义。

type string 必选 | 类型
tools.type
工具类型，此处应为 function

top_logprobs integer 默认值 0 | 返回概率数量
指定每个输出 token 位置最有可能返回的 token 数量，每个 token 都有关联的对数概率。仅当 logprobs 为 true 时可以设置本参数。

> **注意**
> 带深度思考能力模型不支持该字段，深度思考能力模型参见 文档。

取值范围： [0, 20]

top_p number 默认值 0.7 | 核采样阈值
核采样概率阈值。模型会考虑概率质量在 top_p 内的 token 结果。
当取值为 0 时模型仅考虑对数概率最大的一个 token。0.1 意味着只考虑概率质量最高的前 10% 的 token，取值越大生成的随机性越高，取值越低生成的确定性越高。
通常建议仅调整 temperature 或 top_p 其中之一，不建议两者都修改。

> **注意**

> 调用下列模型时字段取值固定为 `0.95`，手动指定的参数值将被忽略：
>
> - `doubao-seed-2-0-pro-260215`
> - `doubao-seed-2-0-lite-260215`
> - `doubao-seed-1-8-251228`

取值范围： `[0, 1]`

响应参数

非流式调用响应

choices `object[]` | 生成结果
本次请求的模型输出内容

finish_reason `string` | 结束原因
`choices.finish_reason`
模型停止生成 token 的原因。

- `stop`：模型输出自然结束，或因命中请求参数 `stop` 中指定的字段而被截断。
- `length`：模型输出因达到模型输出限制而被截断，有以下原因：
  - 触发 `max_tokens` 限制（回答内容的长度限制）。
  - 触发 `max_completion_tokens` 限制（思维链内容 + 回答内容的长度限制）。
  - 触发 `context_window` 限制（输入内容 + 思维链内容 + 回答内容的长度限制）。
- `content_filter`：模型输出被内容审核拦截。
- `tool_calls`：模型调用了工具。

index `integer` | 序号
`choices.index`
当前元素在 **choices** 列表的索引

logprobs `object` | 选项对数概率详情
`choices.logprobs`
当前内容的对数概率信息

content `object[]` | 消息内容
`choices.logprobs.content`
message 列表中每个 content 元素中的 token 对数概率信息

bytes `integer[]` | 字节
`choices.logprobs.content.bytes`
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空

logprob `number` | 对数概率值
`choices.logprobs.content.logprob`
当前 token 的对数概率

token string | Token
choices.logprobs.content.token
当前 token

top_logprobs object[] | 候选概率
choices.logprobs.content.top_logprobs
在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 top_logprobs 指定的数量要少

bytes integer[] | 字节
choices.logprobs.content.top_logprobs.bytes
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空

logprob number | 对数概率值
choices.logprobs.content.top_logprobs.logprob
当前 token 的对数概率

token string | Token
choices.logprobs.content.top_logprobs.token
当前 token

message object | 消息
choices.message
模型输出的内容

content string | 消息内容
choices.message.content
模型生成的消息内容

role string | 角色
choices.message.role
内容输出的角色，此处固定为 assistant

encrypted_content string | 加密思考内容
choices.message.encrypted_content
思考内容加密原文。经加密及压缩处理后的思考内容原文。
相关文档：

- 关键规则
- 回传思考内容加密块使用示例

模型支持：

- doubao-seed-2-0-lite-260428 及后续版本

reasoning_content string | 思维链内容
choices.message.reasoning_content
模型处理问题的思维链内容。
模型支持：

- doubao-seed-1.8 及后续模型
- deepseek-v4-pro
- deepseek-v4-flash

- `deepseek-v3.2`

tool_calls `object[]` | 工具调用
`choices.message.tool_calls`
模型生成的工具调用

function `object` | 函数信息
`choices.message.tool_calls.function`
模型调用的函数

arguments `string` | 函数参数
`choices.message.tool_calls.function.arguments`
模型生成的用于调用函数的参数，JSON 格式。 模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效

name `string` | 函数名
`choices.message.tool_calls.function.name`
模型调用的函数名称

id `string` | ID
`choices.message.tool_calls.id`
调用的工具的 ID

type `string` | 类型
`choices.message.tool_calls.type`
工具类型，当前仅支持 `function`

moderation_hit_type `string` | 审核命中类型
`choices.moderation_hit_type`
模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

- `severe_violation` ：模型输出文字涉及严重违规。
- `violence` ：模型输出文字涉及激进行为。

> **注意**
>
> 注意：当前只有 视觉理解模型 支持返回该字段，且只有在方舟控制台 接入点配置页面 或者 CreateEndpoint 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

created `integer` | 创建时间
本次请求创建时间的 Unix 时间戳（秒）

id `string` | 请求 ID
本次请求的唯一标识

model `string` | 模型名称
本次请求实际使用的模型名称和版本

object `string` | 对象类型
固定为 `chat.completion`

service_status `object` | 服务状态
本次请求附带的服务状态信息，例如是否触发了模型降级（fallback）

model_fallback object | 模型降级状态
service_status.model_fallback
模型降级（fallback）相关的状态信息

fallback_triggered boolean | 是否触发降级
service_status.model_fallback.fallback_triggered
本次请求是否触发了模型降级

original_model string | 原始模型
service_status.model_fallback.original_model
触发降级前，请求最初指定的模型名称

service_tier string | 推理模式
本次请求实际使用的推理模式。

- scale：本次请求使用 在线推理（TPM 保障包） 模式。
- default：本次请求使用 在线推理（常规） 模式。
- fast：本次请求使用 在线推理（低延迟） 模式。

usage object | Token 用量
本次请求的 token 用量

completion_tokens integer | 输出 Token 数
usage.completion_tokens
模型输出内容花费的 token

completion_tokens_details object | 输出 Token 明细
usage.completion_tokens_details
模型输出内容花费的 token 的细节

reasoning_tokens integer | 思维链 Token 数
usage.completion_tokens_details.reasoning_tokens
输出思维链内容花费的 token 数。 支持输出思维链的模型请参见 文档

prompt_tokens integer | 输入 Token 数
usage.prompt_tokens
输入给模型处理的内容 token 数量

prompt_tokens_details object | 输入 Token 明细
usage.prompt_tokens_details
输入给模型处理的内容 token 数量的细节

cached_tokens integer | 缓存命中 Token 数
usage.prompt_tokens_details.cached_tokens
缓存命中的输入内容（含文本、音频等所有类型）所消耗的 token 总数

audio_cached_tokens integer | 音频缓存 Token 数
usage.prompt_tokens_details.audio_cached_tokens
缓存命中的音频输入内容所消耗的 token 数量

audio_tokens integer | 音频 Token 数
usage.prompt_tokens_details.audio_tokens
音频输入内容所消耗的 token 数量

total_tokens integer | 总 Token 数
usage.total_tokens
本次请求消耗的总 token 数量（输入 + 输出）

流式调用响应

choices object[] | 生成结果
本次请求的模型输出内容

delta object | 增量消息
choices.delta
模型输出的增量内容

content string | 消息内容
choices.delta.content
模型生成的消息内容

encrypted_content string | 加密思考内容
choices.delta.encrypted_content
思考内容加密原文。经加密及压缩处理后的思考内容原文。
相关文档：

- 关键规则
- 回传思考内容加密块使用示例

> **说明**
> 流式输出场景下，将在思考内容输出完成后、正式应答内容输出前，输出包含完整 encrypted_content 的数据。其中 content 与 reasoning_content 字段均为空。

模型支持：

- doubao-seed-2-0-lite-260428 及后续版本

reasoning_content string | 思维链内容
choices.delta.reasoning_content
思考内容原文。
自 doubao-seed-2-0-lite-260428 版本起，返回思考内容摘要。

> **注意**
> 针对长文本生成、深度推理等耗时场景，建议适当调大首 Token 超时时间（TTFT）与逐 Token 生成超时时间（TPOT），避免请求因超时而中断。

模型支持：

- doubao-seed-1.8 及后续模型
- deepseek-v4-pro
- deepseek-v4-flash
- deepseek-v3.2

版权所有©北京火山引擎科技有限公司

role string | 角色
choices.delta.role
内容输出的角色，此处固定为 assistant

tool_calls object[] | 工具调用
choices.delta.tool_calls
模型生成的工具调用

index integer | 序号
choices.delta.tool_calls.index
工具调用在数组中的索引位置

function object | 函数信息
choices.delta.tool_calls.function
模型调用的函数

arguments string | 函数参数
choices.delta.tool_calls.function.arguments
模型生成的用于调用函数的参数，JSON 格式。 模型并不总是生成有效的 JSON，并且可能会虚构出一些您的函数参数规范中未定义的参数。在调用函数之前，请在您的代码中验证这些参数是否有效

name string | 函数名
choices.delta.tool_calls.function.name
模型调用的函数名称

id string | ID
choices.delta.tool_calls.id
调用的工具的 ID

type string | 类型
choices.delta.tool_calls.type
工具类型，当前仅支持 function

index integer | 序号
choices.index
当前元素在 **choices** 列表的索引

finish_reason string | 结束原因
choices.finish_reason
模型停止生成 token 的原因。

- stop ：模型输出自然结束，或因命中请求参数 stop 中指定的字段而被截断。
- length ：模型输出因达到模型输出限制而被截断，有以下原因：
  - 触发 max_tokens 限制（回答内容的长度限制）。
  - 触发 max_completion_tokens 限制（思维链内容 + 回答内容的长度限制）。
  - 触发 context_window 限制（输入内容 + 思维链内容 + 回答内容的长度限制）。
- content_filter ：模型输出被内容审核拦截。
- tool_calls ：模型调用了工具。

logprobs object | 选项对数概率详情
choices.logprobs
当前内容的对数概率信息

content object[] | 消息内容
choices.logprobs.content
message 列表中每个 content 元素中的 token 对数概率信息

bytes integer[] | 字节
choices.logprobs.content.bytes
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空

logprob number | 对数概率值
choices.logprobs.content.logprob
当前 token 的对数概率

token string | Token
choices.logprobs.content.token
当前 token

top_logprobs object[] | 候选概率
choices.logprobs.content.top_logprobs
在当前 token 位置最有可能的标记及其对数概率的列表。在一些情况下，返回的数量可能比请求参数 top_logprobs 指定的数量要少

bytes integer[] | 字节
choices.logprobs.content.top_logprobs.bytes
当前 token 的 UTF-8 值，格式为整数列表。当一个字符由多个 token 组成（表情符号或特殊字符等）时可以用于字符的编码和解码。如果 token 没有 UTF-8 值则为空

logprob number | 对数概率值
choices.logprobs.content.top_logprobs.logprob
当前 token 的对数概率

token string | Token
choices.logprobs.content.top_logprobs.token
当前 token

moderation_hit_type string | 审核命中类型
choices.moderation_hit_type
模型输出文字含有敏感信息时，会返回模型输出文字命中的风险分类标签。

- severe_violation：模型输出文字涉及严重违规。
- violence：模型输出文字涉及激进行为。

> **注意**
>
> 注意：当前只有 视觉理解模型 支持返回该字段，且只有在方舟控制台 接入点配置页面 或者 CreateEndpoint 接口中，将内容护栏方案（ModerationStrategy）设置为基础方案（Basic）时，才会返回风险分类标签。

created integer | 创建时间
本次请求创建时间的 Unix 时间戳（秒）

id string | 请求 ID
本次请求的唯一标识

model string | 模型名称
本次请求实际使用的模型名称和版本

object string | 对象类型
固定为 chat.completion.chunk

service_status object | 服务状态
本次请求附带的服务状态信息，例如是否触发了模型降级（fallback）

model_fallback object | 模型降级状态
service_status.model_fallback
模型降级（fallback）相关的状态信息

fallback_triggered boolean | 是否触发降级
service_status.model_fallback.fallback_triggered
本次请求是否触发了模型降级

original_model string | 原始模型
service_status.model_fallback.original_model
触发降级前，请求最初指定的模型名称

service_tier string | 推理模式
本次请求实际使用的推理模式。

- scale：本次请求使用 在线推理（TPM 保障包） 模式。
- default：本次请求使用 在线推理（常规） 模式。
- fast：本次请求使用 在线推理（低延迟） 模式。

usage object | Token 用量
本次请求的 token 用量。
流式调用时，默认不统计 token 用量信息，返回值为 null。如需统计，需设置 stream_options.include_usage 为 true。

版权所有©北京火山引擎科技有限公司